

딥러닝 기반 인공지능 생성 뉴스 탐지

A Study on Deep Learning-Based Detection of AI-Generated News

장예훈
서강대학교 AI·SW 대학원


서론

인공지능의 발전으로 AI기자가 작성한 기사가 점차 증가될 것으로 전망되고 있다. 생성형 인공지능 신속한 콘텐츠 제작, 비용 절감 등의 장점에도 불구하고 잘못된 정보나 허위 사실이 포함된 뉴스 작성에 취약하다는 치명적인 단점이 있다. 잘못 작성된 뉴스는 사회적, 정치적으로도 큰 파장을 일으킬 수 있기에 생성형 인공지능 작성 기사에 대한 탐지 기술이 필요하고, 이에 따른 연구가 활발히 진행되고 있다.

본 연구는 다양한 트랜스포머 기반 딥러닝 기술을 활용하여 생성형 인공지능 작성 기사를 분류해보고 그 결과를 비교해보자 한다.



美 해리스 부대통령 총상 오보




美 고등학교 축구기사 오류(내용의 반복성, 세부내용 누락 등)

2. 사용 모델

본 연구에서는 KoBART와 KoELECTRA 모델을 사용하였고, 각 모델의 오분류 항목에 대한 보완을 위해 softmax값에 대한 soft voting을 한 앙상블한 결과까지 총 3개의 모델을 비교했다.

1) KoBART (Korean Bidirectional and Auto-Regressive Transformer)

BART는 입력 텍스트에 노이즈를 주고 원문으로 복구하는 Autoencoder 방식으로 학습하며, KoBART는 Korean Wiki 등 다양한 한국어 말뭉치를 학습하여 한국어 문장에 특화된 모델이다.



BART 모델 학습 원리(출처 : <https://github.com/SKT-AI/KoBART>)

2) KoELECTRA (Efficiently Learning an Encoder that Classifies Token Replacement Accuracy)

ELECTRA 모델은 학습 과정에서 일부 토큰을 fake token으로 바꾸고 discriminator 과정을 거쳐 이를 탐지하는 binary classification 문제를 해결하는 방식으로 학습한다. KoELECTRA 모델은 한국어 뉴스, 위키, 모두의 말뭉치 등을 학습하여 한국어 문장에 특화된 모델이다.

방법

1. 데이터셋

기존 작성 뉴스 데이터는 AI-HUB '뉴스 기사 기계독해 데이터' 에서 확보, 학습 및 검증 데이터로 20,000개의 데이터를 추출하고 최종 테스트 데이터로 8,000개 데이터를 사용했다.

AI 작성 뉴스를 확보하기 위해 OPENAI API를 사용하여 기존 뉴스 기반으로 새 뉴스 작성을 지시했다. (model = GPT-3.5-turbo)

Null반환 데이터 등에 대한 전처리를 통해 최종 데이터 55,942개를 확보했다.

	학습 및 검증	테스트	합계
기존 뉴스	20,000	8,000	28,000
AI 작성 뉴스(전처리 전)	20,000	8,000	28,000
AI 작성 뉴스(전처리 후)	19,993	7,949	27,942
계	39,993	15,949	55,942

AI 작성 데이터의 대표적인 오류는 아래와 같다.

구분	기존 뉴스	AI 생성 뉴스
제목 오류	두산중공업, 연말까지 일부 휴업... 400명 규모	두산중공업, 400명 휴업으로 연말까지
정보 삭제	인천시립박물관과 4개 분관(송암미술관·검단선사박물관·한국이민사박물관·인천도시역사관) 도 재개관했다.	또한 인천시립박물관과 분관들도 재개관하여... (중략)
비정상적 종결	알려져 뜨거운 반응이 예상된다.	피아노 연주로 뜨거운 반응 예상.
맥락 오류	영화 '그들만의 리그'의 실제 주인공이자 미국 여자 프로야구의 전설인 매리 플렛이 사망했다. 향년 101세.	미국 여자 프로야구 전설 매리 플렛이 영화 '그들만의 리그'의 실제 주인공으로 알려졌으며, 101세의 나이로 사망했다.
정보 오류	코로나19 감독 대상 환자(PDP) 가운데...	코로나19 의심환자(PDP) 중

결과

각 모델별 분류지표 비교

실험 결과 뉴스 내용에 대한 각 모델별 분류지표는 다음과 같다.

* 측정 지표 : Accuracy, AUROC, Precision, Recall, F1 Score

	KoELECTRA	KoBART	Ensemble
Accuracy	0.8029	0.9995	0.9992
AUROC	0.8845	0.9999	0.9996
Precision	0.7649	0.9992	0.9990
Recall	0.8729	0.9997	0.9995
F1 Score	0.8154	0.9995	0.9992

세 모델 모두 모든 지표에서 0.70이상의 점수를 기록했으며, 특히 KoBART 모델이 모든 지표에서 우수한 점수를 기록했다.

1) Accuracy : 세 모델 모두 0.80이상의 정확도를 기록하였으며, KoBART의 경우 0.9995의 정확도를 보여 대부분의 AI작성 기사를 탐지했다.

2) AUROC : KoBART모델이 0.9999의 Accuracy를 기록하여 이진분류성능이 우수함을 보였다.

3) Precision : KoELECTRA모델과 비교하였을 때 0.9992의 점수를 기록하여 오분류를 거의 하지 않음을 보여준다.

4) Recall : 실제로 AI가 작성한 기사 중 모델이 AI작성 뉴스라고 탐지한 비율로, Precision과 마찬가지로 KoBART모델이 0.9997의 높은 점수를 기록하여 대부분의 AI작성 뉴스를 탐지함을 보여주었다.

5) F1 Score : Precision과 Recall의 조화평균으로 KoBART모델이 가장 높은 점수인 0.9995를 기록하였다.

결론

- KoBART 모델 활용 시 생성형 인공지능 활용 뉴스에 대한 유의미한 분류 모델 구현이 가능함을 확인했다.
- 향후 KULLM, KLUE-BERT와 같은 다양한 한국어 특화 언어모델 활용하여 데이터를 생성 후 학습하여 분류모델의 범용성을 높일 예정이다.

• 본 연구에 사용된 데이터는 AI 허브(aihub.or.kr)에서 다운로드 받을 수 있습니다.